

SciML 2: Generative models

E. Franck

Master CSMI, Strasbourg University

01/09/2025

1. Principe et 1ieres approches

Types d'Apprentissage

- Pour le moment on a considérer l'apprentissage supervisé:
 - On a des données d'entrées et de sorties
 - On cherche à apprendre une relation déterministe qui mappe les entrées aux sorties

$$\min_{\theta} \sum_{i=1}^N \mathcal{L}(f(x_i; \theta), y_i)$$

- Autre type d'apprentissage:
 - Apprentissage non supervisé (déterminer des structures dans les données sans sorties associées)
 - Apprentissage par renforcement (déterminer une politique d'actions pour maximiser une récompense cumulative)
- **Apprentissage non supervisé:**
 - clustering,
 - réduction de dimensionnalité,
 - dictionnaires creux,
 - estimation de densité et modèles génératifs, etc.

Modèles génératifs

Objectives (Estimation de densité): Soit des données $x_1, \dots, x_n \in \mathbb{R}^d$ issues d'une distribution inconnue de densité $p_{\text{target}}(x)$. On souhaite estimer cette distribution, c'est-à-dire construire un modèle $p_\theta(x)$ qui approxime $p_{\text{target}}(x)$.

Objectives (Modèles génératifs): Soit des données $x_1, \dots, x_n \in \mathbb{R}^d$ issues d'une distribution inconnue de densité $p_{\text{target}}(x)$. Un modèle génératif q_θ est processus capable de générer de nouvelles données \tilde{x}) selon une loi qui approche $p_{\text{target}}(x)$.

- Un modèle d'estimation de densité est aussi un modèle génératif.
- Un modèle génératif ne donne pas forcément une estimation de densité explicite. Il s'agit d'un processus d'échantillonnage. Il caractérise donc implicitement la densité.

Objectives (modèles génératifs conditionnels): On peut aussi vouloir construire des modèles génératifs conditionnels. C'est-à-dire des modèles capables de générer des données x conditionnellement à une entrée y . On caractérise donc implicitement la densité conditionnelle $p_{\text{target}}(x | y)$.

Applications

- Génération d'images réalistes (GANs, VAEs)
- Synthèse de texte (modèles de langage, GPT)
- Modélisation de la distribution de données complexes (flux normaux, modèles variationnels)
- Synthèse de molécules en chimie et biologie computationnelle
- Simulation de systèmes physiques (modèles basés sur la physique, réseaux de neurones génératifs)
- Amélioration de la résolution d'images (super-résolution)
- Traduction automatique et génération de discours

Qu'est ce qu'on minimise ?

- **Maximum de vraisemblance:** qui consiste à maximiser la probabilité des données observées sous le modèle.

$$\theta^* = \arg \max_{\theta} \prod_{i=1}^N p_{\theta}(x_i)$$

- **Minimisation de la divergence entre la distribution réelle et la distribution modélisée:**

$$\theta^* = \arg \min_{\theta} D(p_{\text{target}} \| p_{\theta}) = \arg \min_{\theta} \int p_{\text{target}}(x) \log \left(\frac{p_{\text{target}}(x)}{p_{\theta}(x)} \right) dx$$

- Les deux approches sont équivalentes lorsque la divergence choisie est la divergence de Kullback-Leibler (KL).
- Pk ?
 - ▶ En pratique on a souvent pas accès à p_{target} mais seulement à des échantillons issus de cette distribution.
 - ▶ Kl vers Maximum de vraisemblance:
 - ▶ On approxime l'intégrale par une somme sur les échantillons.

$$\theta^* = \arg \min_{\theta} \int p_{\text{target}}(x) \log \left(\frac{p_{\text{target}}(x)}{p_{\theta}(x)} \right) dx \approx \arg \min_{\theta} \sum_{i=1}^N \log \left(\frac{p_{\text{target}}(x_i)}{p_{\theta}(x_i)} \right) = \arg \max_{\theta} \sum_{i=1}^N \log(p_{\theta}(x_i))$$

1er modèle de densité: mélange de Gaussiennes

- On modélise la densité comme une combinaison linéaire de K densités gaussiennes:

$$p_{\theta}(x) = \sum_{k=1}^K \pi_k \mathcal{N}(x | \mu_k, \Sigma_k)$$

où $\theta = \{\pi_k, \mu_k, \Sigma_k\}_{\{k=1\}}^K$ sont les paramètres du modèle, avec π_k les poids des composantes (somme à 1), μ_k les moyennes et Σ_k les matrices de covariance.

- On peut apprendre les paramètres via l'algorithme EM (Expectation-Maximization)
- Implicitement cet algorithme maximise la vraisemblance des données sous le modèle.




Figure 1: "Exemple de mélange de Gaussiennes pour modéliser une distribution complexe. Google Image"

1er modèle génératif: auto-encodeur variationnel (VAE)

- Un VAE est un modèle génératif probabiliste qui apprend une représentation latente des données.
- Il se compose de deux parties:
 - Un encodeur qui mappe les données d'entrée \mathbf{x} vers une distribution latente $q_{\phi}(\mathbf{z} \mid \mathbf{x})$.
 - Un décodeur qui mappe les échantillons de la distribution latente vers la distribution des données $p_{\theta}(\mathbf{x} \mid \mathbf{z})$.




Figure 2: VAE. Lil Blog

- L'apprentissage consiste à maximiser la vraisemblance marginale des données. En pratique on utilise une estimation inférieure (ELBO).

2. Flot Normalisé

Idée principale

- Contrairement à d'autres méthodes les flots normalisés permettent de construire explicitement la densité.

Idea: Soit la densité cible $p_{\text{target}}(\mathbf{x})$. L'idée est de construire une transformation bijective $f : \mathbb{R}^d \rightarrow \mathbb{R}^d$ telle que si $\mathbf{z} \sim p_0(\mathbf{z})$ connue alors $\mathbf{x} = f(\mathbf{z})$ suit la densité cible $p_{\text{target}}(\mathbf{x})$.

- Par définition des loi de probabilité:

$$\int_X p_{\text{target}}(\mathbf{x}) d\mathbf{x} = \int_Z p_0(\mathbf{z}) d\mathbf{z} = \int_{f^{-1}(X)} p_0(\mathbf{z}) d\mathbf{z} = 1$$

- Par le changement de variable $\mathbf{z} = f^{-1}(\mathbf{x})$ on a:

$$\int_X p_{\text{target}}(\mathbf{x}) d\mathbf{x} = \int_X p_0(f^{-1}(\mathbf{x})) |\det J_{f^{-1}}(\mathbf{x})| d\mathbf{x} = 1$$

- On en déduit l'expression de la densité cible:

$$p_{\text{target}}(\mathbf{x}) = p_0(f^{-1}(\mathbf{x})) |\det J_{f^{-1}}(\mathbf{x})|$$

Principe 2

Remark: Si on a une transformation bijective f alors on peut donc calculer p_{target} à partir de p_0 et de f . Encore plus facilement on échantillonner de p_{target} en échantillonnant de p_0 et en appliquant f .

Idea: Une composition de transformations bijectives est aussi une transformation bijective. On peut donc construire des transformations complexes en composant des transformations simples.




Figure 3: Flow normalisé. Lil Blog

Flot normalisé

Definition (Flots normalisés): Soit $p_0(z)$ une densité de probabilité simple. Un flot normalisé est une transformation bijective $f = f_L \circ \dots \circ f_1$ telle qu'un échantillon de la loi final $p_\theta(x)$ soit obtenue en échantillonnant $z \sim p_0(z)$ puis en calculant $x = f(z)$.

- On peut calculer la densité finale via la formule du changement de variable:

$$p_\theta(x) = p_0(f^{-1}(x)) \prod_{i=1}^L |\det J_{f_i^{-1}}(h_i)|$$

où $h_i = f_{i-1} \circ \dots \circ f_1(z)$ et $h_0 = z$.

Proposition (log probabilité): La log probabilité de x sous le modèle est donnée par:

$$\log p_\theta(x) = \log p_0(f^{-1}(x)) + \sum_{i=1}^L \log |\det J_{f_i^{-1}}(h_i)|$$

Apprentissage

- L'objectif est de minimiser la divergence entre la densité cible $p_{\text{target}}(x)$ et la densité modélisée $p_{\theta}(x)$.

Proposition: Minimiser la divergence de KL revient à maximiser la log vraisemblance des données sous le modèle:

$$\theta^* = \arg \min_{\theta} D_{\text{KL}}(p_{\text{target}} \parallel p_{\theta}) = \arg \max_{\theta} \sum_{i=1}^N \log p_{\theta}(x_i)$$

- La formule de la log probabilité permet de calculer facilement le gradient pour l'optimisation.
- On peut utiliser des algorithmes d'optimisation stochastique (SGD, Adam, etc.) pour apprendre les paramètres θ des transformations f_i
- Comment choisir les transformations f_i ?

Remark (Besoin):

- transformations bijectives
- inversibles facilement calculables
- jacobienes avec déterminant calculable efficacement

Analogie avec les EDO

- Soit $x_0, x_1 \in \mathbb{R}^d$. Une façon de construire une transformation bijective entre x_0 et x_1 est de considérer l'EDO:

$$\begin{cases} \frac{dx(t)}{dt} = v(x(t)) \\ x(0) = x_0 \\ x(1) = x_1 \end{cases}$$

- En effet par le théorème de Cauchy-Lipschitz, si v est suffisamment régulier le flot de cette EDO est reversible en temps: $\Phi_t(0, t, x_0) = \Phi_{-t}(\Phi_t(x_0)) = I_d$

Idea:

- on paramétrise des flux d'EDO
- On discrétise l'EDO pour obtenir une couche
- Si on utilise schéma reversible ou calcul ou si peut calculer le flot exact on aura une couche **inversible**.

Exemple: Nice

- On se donne l'EDO

$$\frac{dx(t)}{dt} = v_{\theta}(x(t)),$$

- On split x en deux parties $x = (x_a, x_b)$ et obtient les deux sous équations

$$\frac{d}{dt} \begin{pmatrix} x_a \\ x_b \end{pmatrix} = \begin{pmatrix} v_{\theta,a}(x) \\ 0 \end{pmatrix}, \quad \frac{d}{dt} \begin{pmatrix} x_a \\ x_b \end{pmatrix} = \begin{pmatrix} 0 \\ v_{\theta,b}(x) \end{pmatrix}$$

- On choisit la paramétrisation:

$$\frac{d}{dt} \begin{pmatrix} x_a \\ x_b \end{pmatrix} = \begin{pmatrix} v_{\theta,a}(x_b) \\ 0 \end{pmatrix}, \quad \frac{d}{dt} \begin{pmatrix} x_a \\ x_b \end{pmatrix} = \begin{pmatrix} 0 \\ v_{\theta,b}(x_a) \end{pmatrix}$$

- On applique le schéma d'Euler explicite pour obtenir les transformations:

$$f_1 : \begin{pmatrix} x_a \\ x_b \end{pmatrix} \mapsto \begin{pmatrix} x_a + \Delta t v_{\theta,a}(x_b) \\ x_b \end{pmatrix}, \quad f_2 : \begin{pmatrix} x_a \\ x_b \end{pmatrix} \mapsto \begin{pmatrix} x_a \\ x_b + \Delta t v_{\theta,b}(x_a) \end{pmatrix}$$

- Ses flot discrets sont exacts pour chaque sous système donc reversible en temps et donc inversible.

Exemple: Nice II

Definition (Couche Nice): Une couche Nice est une transformation bijective $f = f_2 \circ f_1$ où f_1 et f_2 sont définies par:

$$f_1 : \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix} \mapsto \begin{pmatrix} \mathbf{x}_a + \mathbf{v}_{\theta,a}(\mathbf{x}_b) \\ \mathbf{x}_b \end{pmatrix}, \quad f_2 : \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix} \mapsto \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b + \mathbf{v}_{\theta,b}(\mathbf{x}_a) \end{pmatrix}$$

avec $\mathbf{v}_{\theta,a}$ et $\mathbf{v}_{\theta,b}$ des réseaux de neurones.

- Le déterminant de la jacobienne est facile à calculer: $\det J_f(\mathbf{x}) = 1$
- L'inverse est aussi facile à calculer:

$$f_1^{-1} : \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix} \mapsto \begin{pmatrix} \mathbf{x}_a - \mathbf{v}_{\theta,a}(\mathbf{x}_b) \\ \mathbf{x}_b \end{pmatrix}, \quad f_2^{-1} : \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix} \mapsto \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b - \mathbf{v}_{\theta,b}(\mathbf{x}_a) \end{pmatrix}$$

- Globalement en cherchant des splitting ou des EDO nilpotentes on peut construire des transformations bijectives avec des jacobiniennes à déterminants calculables efficacement.

Exemple: RealNVP

- $\frac{d}{dt} \begin{pmatrix} x_a \\ x_b \end{pmatrix} = \begin{pmatrix} w_{\theta,a}(x_b) \odot x_a + s_{\theta,a}(x_b) \\ 0 \end{pmatrix}, \quad \frac{d}{dt} \begin{pmatrix} x_a \\ x_b \end{pmatrix} = \begin{pmatrix} 0 \\ w_{\theta,b}(x_a) \odot x_b + s_{\theta,b}(x_a) \end{pmatrix}$

On va considère que la 1er couche mais la situation est similaire pour la seconde couche. On a

$$\frac{d}{dt} \begin{pmatrix} x_a \\ x_b \end{pmatrix} = \begin{pmatrix} w_{\theta,a}(x_b) \odot x_a + s_{\theta,a}(x_b) \\ 0 \end{pmatrix}$$

-On résout l'équation sur x_a en considérant x_b comme une constante cela donne

$$x_a(t) = \exp(\text{diag}(w_{\theta,a}(x_b))t) \odot x_a(0) + \int_0^{\Delta t} \exp(\text{diag}(w_{\theta,a}(x_b))\tau) \odot s_{\theta,a}(x_b)d\tau$$

- On utilise le fait que si $w_{\theta,a}(x_b)$ est inversible on a

$$\int_0^{\Delta t} \exp(\text{diag}(w_{\theta,a}(x_b))\tau)d\tau = \text{diag}(w_{\theta,a}(x_b))^{-1} \odot (\exp(\text{diag}(w_{\theta,a}(x_b))\Delta t) - 1)$$

Exemple: RealNVP

- ce qui donne

$$\mathbf{x}_a(t) = \exp(\text{diag}(\mathbf{w}_{\theta,a}(\mathbf{x}_b))t) \odot \mathbf{x}_a(0) + \left(\text{diag}(\mathbf{w}_{\theta,a}(\mathbf{x}_b))^{-1} \odot (\exp(\text{diag}(\mathbf{w}_{\theta,a}(\mathbf{x}_b))t) - 1) \right) \odot \mathbf{s}_{\theta,a}(\mathbf{x}_b)$$

- Vu que dans l'idée \mathbf{s} et \mathbf{w} sont des réseaux de neurones on pose $\mathbf{t}_{\theta,a}(\mathbf{x}_b) = \left(\text{diag}(\mathbf{w}_{\theta,a}(\mathbf{x}_b))^{-1} \odot (\exp(\text{diag}(\mathbf{w}_{\theta,a}(\mathbf{x}_b))t) - 1) \right) \odot \mathbf{s}_{\theta,a}(\mathbf{x}_b)$. En faisant ça sur les deux équations on obtient les transformations:

$$f_1 : \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix} \mapsto \begin{pmatrix} \exp(\mathbf{w}_{\theta,a}(\mathbf{x}_b)) \odot \mathbf{x}_a + \mathbf{t}_{\theta,a}(\mathbf{x}_b) \\ \mathbf{x}_b \end{pmatrix}, \quad f_2 : \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix} \mapsto \begin{pmatrix} \mathbf{x}_a \\ \exp(\mathbf{w}_{\theta,b}(\mathbf{x}_a)) \odot \mathbf{x}_b + \mathbf{t}_{\theta,b}(\mathbf{x}_a) \end{pmatrix}$$

qui sont obtenues en prenant le flot exact d'une EDO ce qui assure l'inversibilité.

Definition (Couche RealNVP): Une couche RealNVP est une transformation bijective $f = f_2 \circ f_1$ où f_1 et f_2 sont définies par:

$$f_1 : \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix} \mapsto \begin{pmatrix} \mathbf{x}_a \odot \exp(\mathbf{w}_{\theta,a}(\mathbf{x}_b)) + \mathbf{t}_{\theta,a}(\mathbf{x}_b) \\ \mathbf{x}_b \end{pmatrix}, \quad f_2 : \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix} \mapsto \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \odot \exp(\mathbf{w}_{\theta,b}(\mathbf{x}_a)) + \mathbf{t}_{\theta,b}(\mathbf{x}_a) \end{pmatrix}$$

avec $\mathbf{w}_{\theta,a}$, $\mathbf{w}_{\theta,b}$, $\mathbf{t}_{\theta,a}$ et $\mathbf{t}_{\theta,b}$ des réseaux de neurones.

Exemple: RealNVP III

- Le déterminant de la jacobienne est facile à calculer: $\det J_{f_1}(\mathbf{x}) = \exp\left(\sum(s_{\theta,a}(\mathbf{x}_b))\right)$
- L'inverse est aussi facile à calculer:

$$f_1^{-1} : \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix} \mapsto \begin{pmatrix} (\mathbf{x}_a - t_{\theta,a}(\mathbf{x}_b)) \odot \exp(-s_{\theta,a}(\mathbf{x}_b)) \\ \mathbf{x}_b \end{pmatrix}, \quad f_2^{-1} : \begin{pmatrix} \mathbf{x}_a \\ \mathbf{x}_b \end{pmatrix} \mapsto \begin{pmatrix} \mathbf{x}_a \\ (\mathbf{x}_b - t_{\theta,b}(\mathbf{x}_a)) \odot \exp(-s_{\theta,b}(\mathbf{x}_a)) \end{pmatrix}$$

- Example:




Figure 4: RealNVP. Lil Blog

Exemple: KRNet I

- idée: utiliser une transformation triangulaire:

$$\mathbf{y} = f(\mathbf{x}) = \begin{pmatrix} f_1(x_1) \\ f_2(x_1, x_2) \\ \dots \\ f_d(x_1, x_2, \dots, x_d) \end{pmatrix}$$

- Le réseau va donc enchaîner des transformations qui vont utiliser de plus en plus de variables.

$$f(\mathbf{x}) = f_N \circ f_{O,d}(\mathbf{x}) \circ f_{O,d-1}(\mathbf{x}) \circ \dots \circ f_{O,1}(\mathbf{x})$$

- L'enjeu est maintenant de construire des transformations $f_{O,i}$ bijectives avec Jacobienne à déterminant calculable efficacement.
- La transformation $f_{O,k}$ ne modifie que les composantes 1 à k

Definition (Couche de Squeezing): Une couche de Squeezing est donné par $S_k(\mathbf{x}) = \mathbf{q} \odot \mathbf{x}$ avec $\mathbf{q} = \left(\underbrace{(1, \dots, 1)}_k, \underbrace{(0, \dots, 0)}_{d-k} \right)$ est une transformation bijective.

Exemple: KRNet II

Definition (Couche de rotation): Une couche de rotation est une transformation bijective R_θ définie par:

$$R_\theta(x) = \begin{pmatrix} L & \mathbf{0} \\ \mathbf{0} & I_d \end{pmatrix} \begin{pmatrix} U & \mathbf{0} \\ \mathbf{0} & I_d \end{pmatrix} x$$

avec L, U entrainable

Definition (Block interne): Soit $x = (x_a, x_b)$ in $(\mathbb{R}^k, \mathbb{R}^{d-k})$ un bloc interne $f_i(x)$ est la compose d'une couche d'échelle donnée par:

$$f_{\text{sca}}(x) = \mathbf{a} \odot x + \mathbf{b}$$

avec \mathbf{a} et \mathbf{b} apprennable et d'une couche affine

$$f_{\text{aff}} = \left(x_b \odot (1 + \alpha \tanh(t_\theta(x_a))) + e^\beta \odot \tanh(t_\theta(x_a)) \right)^{x_a}$$

avec α un paramètre β entrainable et t_θ un réseau

Exemple: KRNet III

Definition (Block externe): Soit $\mathbf{x} = (\mathbf{x}_a, \mathbf{x}_b)$ in $(\mathbb{R}^k, \mathbb{R}^{d-k})$ un bloc externe

$$f_{O,k}(\mathbf{x}) = S_k \circ f_{i,L} \dots \circ f_{i,1} \circ R_\theta$$

- Il reste à définir la couche final L_N qui introduit une nonlinéarité assez particulière, appliquée composante par composante donné par :

$$f_{N(x)} = \begin{cases} \beta(x - a) + a, & x \in (-\infty, -a) \\ \varphi^{-1} \circ F \circ \varphi & \\ \beta(x + a) - a, & x \in (a, \infty) \end{cases}$$

avec φ affine et

$$F(x) = \int_0^x f(y) dy$$

Exemple: Residual approach I

- On se donne l'EDO

$$\frac{dx(t)}{dt} = v_{\theta}(x(t)),$$

- On approxime le flot de cette EDO via un schéma de type Euler explicite:

$$x_{i+1} = x_i + \Delta t v_{\theta}(x_i)$$

- Si on veut inverser on résout $g(x_i) = x_i$ par une méthode de **Point fixe** avec

$$g(x_i) = x_{i+1} - \Delta t v_{\theta}(x_i)$$

- Pour converger on a besoin que Δt soit suffisamment petit et que v_{θ} soit Lipschitzien avec constante de Lipschitz L telle que $\Delta t L < 1$.

Definition (Couche résiduelle): Une couche résiduelle est une transformation bijective f définie par:

$$f : x \mapsto x + v_{\theta}(x)$$

où v_{θ} est un réseau de neurones **contractant**

Exemple: Residual approach II

- Comment obtenir une paramétrisation contractante ?

Definition (Spectral normalized layer): Une couche à normalisation spectrale est une couche linéaire $w_\theta : \mathbb{R}^d \rightarrow \mathbb{R}^d$ de la form

$$\mathbf{x}_{l+1} = W_{s,\theta} \mathbf{x}_l$$

avec $W_{s,\theta} = \frac{W}{\Sigma(W)}$ où $\Sigma(W)$ est la plus grande valeur singulière de W et W la matrice de poids associée à la couche.

- La valeur singulière maximale est approximée via une version différentiable de méthode de la puissance.
- Ici on constraint chaque couche à être contractante avec constante de Lipschitz $L = 1$.

Exemple: Neural Splines flows I

Idea: On applique composante par composante une fonction monotone, bijective et différentiable construite comme une spline rationnelle quadratique.

- On se donne $[-c, c]$
- On se donne des noeuds $b_1 < b_2 < \dots < b_{K-1}$ dans $[-c, c]$ avec $b_0 = -c$ et $b_K = c$
- On se donne des images $y_1 < y_2 < \dots < y_{K-1}$ dans $[-c, c]$ avec $y_0 = -c$ et $y_K = c$
- On se donne des dérivées d_0, d_1, \dots, d_K en chaque noeud
- On définit la fonction spline par morceaux:

$$S(x) = \frac{(y_{i+1} - y_i)(x - b_i)^2 + d_i(x - b_i)(b_{i+1} - x)}{(b_{i+1} - b_i)^2 + \left(d_{i+1} + d_i - 2\frac{y_{i+1} - y_i}{b_{i+1} - b_i}\right)(x - b_i)(b_{i+1} - x)}$$

- Determinant jacobienne facile à calculer:
- Inverse facile à calculer via résolution d'une équation quadratique.

Exemple: Neural Splines flows II

Soit une spline vectorielle

$$\mathbf{S} = \begin{pmatrix} S_1(x_1) \\ S_2(x_2) \\ \vdots \\ S_{\frac{d}{2}}(x_{\frac{d}{2}}) \end{pmatrix}$$

Definition (Couche Neural Spline Flow): Une couche Neural Spline Flow est une transformation bijective f définie par une spline vectorielle:





$$\mathbf{x} = \mathbf{S}(\mathbf{x}; (\mathbf{b}, \mathbf{y}, \mathbf{d})_b)$$

ou les paramètres de toutes les splines sont données par $(\mathbf{b}, \mathbf{y}, \mathbf{d})_b = \text{MLP}_{\theta}(\mathbf{x}_a)$ et $(\mathbf{b}, \mathbf{y}, \mathbf{d})_a$ entraînables.

Applications aux PINNs

- Dans la version primaire des PINNs: on échantillonne uniformement les PINNs.

Remark: Pour des problèmes fortement localisé ca nécessite beaucoup de points. En pratique on aimera échantillonner là où il faut.



- On veut échantillonner plus de point là où:
 - le résidu $|r(\mathbf{u}_x)|^2$ est grand
 - le gradient $|\nabla_x \mathbf{u}_x|^2$ est grand
 - un des critères précédent sur une autre variable
- On nomme ce critère $h(\mathbf{u}_\theta)$
- $h(\mathbf{u}_\theta)$ n'est pas une distribution de probabilité ?
comment échantillonner ?

Applications aux PINNs

Idea: apprendre à faire et à mesurer de l'entraînement une densité $p_{\theta_p}(\mathbf{x})$ qui satisfait

$$\theta_p^* = \arg \min_{\theta_p} \text{KL}\left(h(\mathbf{u}_\theta) \mid \mid p_{\theta_p}\right)$$

- Ici $p_{\theta_p} = \mathbb{1}_\Omega \circ \text{FN}_{\theta_p}$ avec FN_{θ_p} un flot normalisé et $\mathbb{1}_\Omega$ un algorithme qui rejette les points qui ne sont pas dans le domaine.
- On développe:

$$\arg \min_{\theta_p} \text{KL}\left(h(\mathbf{u}_\theta)(\mathbf{x}) \mid \mid p_{\theta_p}(\mathbf{x})\right) = \arg \min_{\theta_p} \int_\Omega h(\mathbf{u}_\theta)(\mathbf{x}) \log \left(\frac{h(\mathbf{u}_\theta)(\mathbf{x})}{p_{\theta_p}(\mathbf{x})} \right) d\mathbf{x}$$

$$= \arg \min_{\theta_p} \int_\Omega h(\mathbf{u}_\theta) \log(h(\mathbf{u}_\theta)) d\mathbf{x} - \arg \min_{\theta_p} \int_\Omega h(\mathbf{u}_\theta) \log(p_{\theta_p}) d\mathbf{x} = \arg \min_{\theta_p} - \int_\Omega h(\mathbf{u}_\theta) \log(p_{\theta_p}) d\mathbf{x}$$

- On utilise le fait que

$$\int_\Omega h(\mathbf{u}_\theta) \log(p_{\theta_p}) d\mathbf{x} = \mathbb{E}_{\mathcal{U}} [h(\mathbf{u}_\theta) \log(p_{\theta_p})] = \mathbb{E}_{p_{\theta_p}} \left[\frac{h(\mathbf{u}_\theta)}{p_{\theta_p}} \log(p_{\theta_p}) \right]$$

Applications aux PINNs II

- On applique la méthode de Monte Carlo et donc on va minimiser

$$J_p(\theta_p) = -\frac{1}{n} \sum_{i=1}^n \frac{h(u_\theta)(x_i)}{p_{\theta_p}(x_i)} \log(p_{\theta_p}(x_i))$$

avec des points échantillonner par p_{θ_p} .

- Coté PINNs normalement on minimise

$$J(\theta) = \int_{\Omega} r(u_\theta)(x)^2 dx = \mathbb{E}_{\mathcal{U}} [r(u_\theta)^2] = \mathbb{E}_{p_{\theta_p}} \left[\frac{r(u_\theta)^2}{p_{\theta_p}} \right]$$

- Une fois discréteriser avec Monte Carlo on obtient le problème de Minimisation

$$\theta^* = \arg \min_{\theta} \frac{1}{n} \sum_{i=1}^n \frac{r(u_\theta)^2(x_i)}{p_{\theta_p}(x_i)}$$

Remark:

- Dans l'algorithme on réentraine régulière (toute les k itérations de gradient) le flot normalisé pour sampler de mieux en mieux
- Soit p_{θ_p} est combiné avec une loi uniforme pour assurer de garder un peu de point partout.

Applications aux PINNs III

- On peut proposer d'autre type d'optimisation.
- Par exemple:

$$\theta^*, p_{\theta_p}^* = \arg \min_{\theta} \max_{p_{\theta_p} \in V} \int_{\Omega} r(u_{\theta})^2(x) p_{\theta_p}(x) d(x)$$

avec $V = \{p_{\theta_p}, \int p_{\theta_p}(x) dx = 1, p_{\theta_p}(x) > 0\}$

Remark:

- On peut montrer que résoudre ce problème fait tendre le résidu et

$$\frac{r(u_{\theta})^2(x)}{\int_{\Omega} r(u_{\theta})^2(x) dx} \rightarrow \mu_{\Omega}$$

avec μ_{Ω} la mesure de la loi uniforme. Cela pousse donc l'apprentissage à minimiser le plus uniformément possible le résidu

- Pour que le théorème marche on a besoin que la constante de Lipschitz de p_{θ_p} soit plus petite que 1.

Applications aux PINNs IV

On résout donc le problème modifié:

$$\theta^*, \theta_p^* = \arg \min_{\theta} \max_{\theta_p} \int_{\Omega} r(\mathbf{u}_{\theta})^2(x) p_{\theta_p}(x) d(x) - \beta \int | \nabla_x p_{\theta_p}(x) |^2 dx$$

Remark: On va alterner l'optimisation selon θ et θ_p

- Pour θ on va minimiser:

$$\int_{\Omega} r(\mathbf{u}_{\theta})^2(x) p_{\theta_p}(x) \approx \sum_{i=1}^n r(\mathbf{u}_{\theta})^2(x_i)$$

- Pour θ_p on va maximiser

$$\int_{\Omega} r(\mathbf{u}_{\theta})^2(x) p_{\theta_p}(x) d(x) - \beta \int | \nabla_x p_{\theta_p}(x) |^2 dx \approx \sum_{i=1}^n \frac{r(\mathbf{u}_{\theta})^2(x_i)}{p_{\theta_p}^k(x_i)} p_{\theta_p}(x_i) - \sum_{i=1}^n \frac{| \nabla_x p_{\theta_p}(x) |^2}{p_{\theta_p}^k(x_i)}$$

ou $p_{\theta_p}^k(x_i)$ est la distribution à l'itération d'avant utilisée pour échantillonner

3. Flot Normalisé continue

version continue

- On a vu que les flot normalisé se comprenaient comme des discrétilisations reversibles d'EDO.
- On peut donc directement travailler avec les EDO.

Soit $\mathbf{x}_{\text{target}}$ un échantillon de la distribution cible p_{target} et \mathbf{z}_0 un échantillon de la distribution simple p_0 .

- On considère l'EDO:

$$\begin{cases} \frac{d\mathbf{x}(t)}{dt} = \mathbf{v}_\theta(\mathbf{x}(t), t) \\ \mathbf{x}(0) = \mathbf{z}_0 \end{cases}$$

Remark: Si on a une particule qui suit l'équation précédente alors la densité $p(\mathbf{x}, t)$ de la particule à l'instant t satisfait l'équation de continuité:

$$\frac{\partial p(\mathbf{x}, t)}{\partial t} + \nabla_{\mathbf{x}} \cdot (p(\mathbf{x}, t) \mathbf{v}_\theta(\mathbf{x}, t)) = 0$$

- On développe

$$\frac{\partial p(\mathbf{x}, t)}{\partial t} = -p(\mathbf{x}, t) \nabla_{\mathbf{x}} \cdot \mathbf{v}_\theta(\mathbf{x}, t) - \mathbf{v}_\theta(\mathbf{x}, t) \cdot \nabla_{\mathbf{x}} p(\mathbf{x}, t)$$

Flot Normalisé continu

- Maintenant on regarde l'évolution de la densité pour une particule $\mathbf{x}(t)$:

$$\frac{d}{dt} p(\mathbf{x}(t), t) = \frac{\partial p(\mathbf{x}, t)}{\partial t} + \frac{d\mathbf{x}(t)}{dt} \cdot \nabla_{\mathbf{x}} p(\mathbf{x}, t)$$

- Maintenant on introduit l'équation de continuité:

$$\frac{d}{dt} p(\mathbf{x}(t), t) = -p(\mathbf{x}(t), t) \nabla_{\mathbf{x}} \cdot \mathbf{v}_{\theta}(\mathbf{x}(t), t)$$

- On multiplie par $\frac{1}{p(\mathbf{x}(t), t)}$ et on intègre en temps:

$$\frac{d}{dt} \log p(\mathbf{x}(t), t) = -\nabla_{\mathbf{x}} \cdot \mathbf{v}_{\theta}(\mathbf{x}(t), t)$$

Proposition: En intégrant on obtient la log densité de la particule à l'instant t :

$$\log p(\mathbf{x}(t), t) = \log p_0(\mathbf{x}(0)) - \int_0^t \nabla_{\mathbf{x}} \cdot \mathbf{v}_{\theta}(\mathbf{x}(\tau), \tau) d\tau = \log p_0(\mathbf{z}_0)$$

Flot Normalisé continu

- En pratique on va donc minimiser

$$\theta^* = \arg \min_{\theta} \log p_{t=1}(x_{\text{target}}) = \arg \min_{\theta} -\log p_0(x(0)) + \int_0^1 \nabla_x \cdot v_{\theta}(x(\tau), \tau) d\tau$$

- Cela nécessite de résoudre l'EDO avant pour obtenir $x(\tau)$.
- Le calcul de la divergence de v_{θ} peut être couteux en haute dimension.
- Le calcul du gradient nécessite soit de calculer l'adjoint soit de différentier par rétro-propagation dans le schéma en temps.

Remark: Pas facilement utilisable en pratique

- La méthode qu'on va introduire permet de conserver l'approche ODE en simplifiant l'entraînement.

4. Flow matching

Principe

Remark: Les méthodes de flow matching utilise une édo pour transformer une loi simple en une loi cible mais propose un entraînement nettement plus simple que précédemment

Objectives: On souhaite trouver $v(x, t)$ tel que la densité générée p_t tel que $p_{t=0} = p_0$ la densité de base et $p_{t=1} = p_{\text{target}}$ la densité cible. Pour cela on a accès à des échantillons de p_{target} d'échantillon x_1 et on échantillonne x_0 de p_0 .

- On va commencer par définir l'objectif d'entraînement de la méthode flow matching.

Definition (Fonction de coût de la méthode flow matching): On souhaite minimiser la fonction de coût:

$$\mathbb{E}_{x(t) \sim p_t} [\| v_{t,\theta}(x(t)) - v_t^*(x(t)) \|^2]$$

En pratique le champ de vitesse cible v^* est inconnu. L'enjeu de la méthode est de remplacer cette fonction de coût

- par une fonction de coût calculable.

Construction I

- L'idée est d'utiliser la connaissance des échantillons de p_{target}
- On va définir la trajectoire de notre distribution à partir d'une densité conditionnelle $p_{t|1}(x | x_1)$

$$p_t(x) = \int p_{t|1}(x | x_1) p_{\text{target}}(x_1) dx_1$$

avec $p_0(x | x_1) = p_0(x)$ et $p_1(x | x_1) = \delta(x - x_1)$

Definition (Chemin de probabilité conditionnel): Le chemin de probabilité conditionnel est défini par la densité conditionnelle $p_{t|1}(x | x_1)$ telle que $p_0(x | x_1) = p_0(x)$ et $p_1(x | x_1) = \delta(x - x_1)$

- Par la suite on va
 - exprimer le champ de vitesse cible v^* en fonction d'un champ conditionnel et de $p_{t|1}$
 - Montrer que le champ généré à partir du champ conditionnel est le même que celui généré par le champ de vitesse cible
 - Monter que la fonction de coût peut s'écrire en fonction du champ conditionnel uniquement.
 - proposer des chemins conditionnels simples pour lesquels on peut calculer le champ conditionnel explicitement.
 - Entraîner le modèle via la fonction de coût simplifiée.

Construction II

- On suppose que la densité conditionnelle $p_{t|1}(x | x_1)$ satisfait l'équation de continuité:

$$\frac{\partial p_{t|1}(x | x_1)}{\partial t} + \nabla_x \cdot (p_{t|1}(x | x_1) v_t(x | x_1)) = 0$$




Figure 6: Schéma conditionnel. Cours flow matching
Cambridge

- On peut aussi définir le champ de vitesse à partir du champ conditionnel:

$$v_t(x) = \mathbb{E}_{p_{1|t}(x_1 | x)} [v_t(x | x_1)] = \int v_t(x | x_1) p_{1|t}(x_1 | x) dx_1$$

Proposition: Le champ de vitesse $v_t(x)$ défini ci-dessus génère la même trajectoire de densité p_t que le champ de vitesse cible $v_t^*(x)$.

Construction III

$$\begin{aligned}
 \frac{d}{dt} p_t &= \int \frac{\partial p_{t|1}(\mathbf{x} | \mathbf{x}_1)}{\partial t} p_{\text{target}}(\mathbf{x}_1) d\mathbf{x}_1 \\
 &= - \int \nabla_{\mathbf{x}} \cdot (p_{t|1}(\mathbf{x} | \mathbf{x}_1) \mathbf{v}_t(\mathbf{x} | \mathbf{x}_1)) p_{\text{target}}(\mathbf{x}_1) d\mathbf{x}_1, \\
 &= - \int \nabla_{\mathbf{x}} \cdot (p_{t|1}(\mathbf{x} | \mathbf{x}_1) \mathbf{v}_t(\mathbf{x} | \mathbf{x}_1) p_{\text{target}}(\mathbf{x}_1)) d\mathbf{x}_1 \\
 &= - \nabla_{\mathbf{x}} \cdot \left(\int p_{t|1}(\mathbf{x} | \mathbf{x}_1) \mathbf{v}_t(\mathbf{x} | \mathbf{x}_1) p_{\text{target}}(\mathbf{x}_1) d\mathbf{x}_1 \right) \\
 &= - \nabla_{\mathbf{x}} \cdot \left(\int \mathbf{v}_t(\mathbf{x} | \mathbf{x}_1) \frac{p_{t|1}(\mathbf{x} | \mathbf{x}_1) p_{\text{target}}(\mathbf{x}_1)}{p_t(\mathbf{x})} p_t(\mathbf{x}) d\mathbf{x}_1 \right) \\
 &= - \nabla_{\mathbf{x}} \cdot \left(\int \mathbf{v}_t(\mathbf{x} | \mathbf{x}_1) p_{1|t}(\mathbf{x}_1 | \mathbf{x}) p_t(\mathbf{x}) d\mathbf{x}_1 \right)
 \end{aligned}$$

- par le théorème de Bayes. Ensuite par la définition de \mathbf{u}_t on a:

$$\frac{d}{dt} p_t = - \nabla_{\mathbf{x}} \cdot (\mathbf{v}_t(\mathbf{x}) p_t(\mathbf{x}))$$

Construction IV

- Maintenant qu'on a prouvé que le champ de vitesse générée par le champ conditionnel est le même que celui généré par le champ de vitesse cible on peut donc résoudre l '**EDO associé au champ de vitesse conditionnel et prendre l'espérance conditionnelle pour obtenir la densité à l'instant t.**




Figure 7: Schéma conditionnel. Cours flow matching
Cambridge

- L'objectif de base était de minimiser

$$\mathcal{L}(\theta) = \mathbb{E}_{t \in \mathcal{U}[0,1], \mathbf{x} \sim p_t} [\| \mathbf{v}_{t,\theta}(\mathbf{x}_t) - \mathbf{v}_t^*(\mathbf{x}_t) \|^2]$$

- Puisque $v(\mathbf{x}(t)) = \mathbb{E}_{p_{1|t}(\mathbf{x}_1 | \mathbf{x})} [v_t(\mathbf{x} | \mathbf{x}_1)]$ génère la même trajectoire de densité que $\mathbf{v}_t^*(\mathbf{x})$ on peut minimiser

$$\mathcal{L}(\theta) = \mathbb{E}_{t \in \mathcal{U}[0,1], \mathbf{x} \sim p_t} [\| \mathbf{v}_{t,\theta}(\mathbf{x}_t) - v(\mathbf{x}_t) \|^2]$$

Flow matching conditionnel

Theorem: Soit la fonction de coût

$$\mathcal{L}_{\text{FM}}(\boldsymbol{\theta}) = \mathbb{E}_{t \in \mathcal{U}[0,1], \mathbf{x} \sim p_t} [\| \mathbf{v}_{t,\boldsymbol{\theta}}(\mathbf{x}_t) - \mathbf{v}(\mathbf{x}_t) \|^2]$$

et la fonction de coût

$$\mathcal{L}_{\text{CM}}(\boldsymbol{\theta}) = \mathbb{E}_{t \in \mathcal{U}[0,1], \mathbf{x}_1 \sim p_{\text{target}}, \mathbf{x}_t \sim p_{t(\mathbf{x} \mid \mathbf{x}_1)}} [\| \mathbf{v}_{t,\boldsymbol{\theta}}(\mathbf{x}_t) - \mathbf{v}_t(\mathbf{x}_t \mid \mathbf{x}_1) \|^2]$$

alors on a l'égalité

$$\nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{FM}}(\boldsymbol{\theta}) = \nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{CM}}(\boldsymbol{\theta})$$

- En pratique on va donc minimiser la fonction de coût conditionnelle.

Remark: La magie de la méthode c'est en se donnant un chemin conditionnel on peut calculer explicitement le champ conditionnel $\mathbf{v}_t(\mathbf{x} \mid \mathbf{x}_1)$ et donc la fonction de coût

Chemin de probabilité conditionnel

Definition (Chemin de probabilité conditionnel gaussien): Le chemin de probabilité conditionnel gaussien est défini par la densité conditionnelle

$$p_{t|1}(x | x_1) = \mathcal{N}(x; \mu_t(x_1), \sigma^2(x_1)I_d)$$

Proposition: Le champ de vitesse conditionnel associé au chemin de probabilité conditionnel gaussien est:

$$v_t(x | x_1) = \frac{d\mu_t(x_1)}{dt} + \frac{d\sigma_t(x_1)}{dt} \sigma_t(x_1)^{-1} (x - \mu_t(x_1))$$

- Preuve:
 - Le chemin choisit implique que $x_{t|1} = \mu_t(x_1) + \sigma_t(x_1)x_0$ avec $x_0 \sim p_0 = \mathcal{N}(\mathbf{0}, I_d)$
 - On sait que $\frac{\partial p_{t|1}(x | x_1)}{\partial t} + \nabla_x \cdot (p_{t|1}(x | x_1)v_t(x | x_1)) = 0$ donc

$$\frac{dx_{t|1}}{dt} = v_t(x_{t|1} | x_1)$$

Chemin de probabilité conditionnel II

- On a donc

$$\frac{dx_t |_1}{dt} = v_t(x_{t | 1} | x_1)$$

- Il suffit de calculer la dérivée de $x_{t | 1}$ on obtient

$$v_t(x | x_1) = \frac{d\mu_t(x_1)}{dt} + \frac{d\sigma_t(x_1)}{dt}x_0$$

- On utilise le chemin pour exprimer x_0 en fonction de x : $x_0 = \sigma_t(x_1)^{-1}(x - \mu_t(x_1))$.
- On obtient bien:

$$v_t(x | x_1) = \frac{d\mu_t(x_1)}{dt} + \frac{d\sigma_t(x_1)}{dt}\sigma_t(x_1)^{-1}(x - \mu_t(x_1))$$

Remark: Un chemin classique est un chemin de probabilité conditionnel gaussien avec

$$\mu_t(x_1) = tx_1, \quad \sigma_t = \sigma_0 t + (1 - t)$$

avec μ_0 et σ_0 des hyperparamètres. On obtient

$$v_t(x | x_1) = x_1 - x + \frac{\sigma_0 - 1}{\sigma_0 t + (1 - t)}(x - tx_1)$$

Algorithme

Algorithm:

- Initialiser les paramètres θ du modèle $v_{t,\theta}(x)$
- Pour i de 1 à N_{iter} :
 - Échantillonner x_1 de la distribution cible p_{target}
 - Échantillonner x_0 de la distribution simple p_0
 - Échantillonner t uniformément dans $[0, 1]$
 - Calculer $x_t = \mu_t(x_1) + \sigma_t(x_1)x_0$
 - Calculer le champ conditionnel $v_t(x_t | x_1)$
 - Calculer la perte

$$\mathcal{L} = \| v_{t,\theta}(x_t) - v_t(x_t | x_1) \|^2$$

- Mettre à jour les paramètres θ via une étape de descente de gradient sur \mathcal{L}
- On peut proposer plusieurs chemins conditionnels
- On peut traiter le cas conditionnel où on cherche à générer une distribution conditionnelle $p_{\text{target}}(x | c)$

Flot matching pour les PINNs

- Pour les pinns on construisait une densité qui approchait $h(\mathbf{u}_\theta)$ (typiquement le résidu ou le gradient).
- Contrairement au flot normalisé on a pas accès à la densité qu'on construit donc on peut pas minimiser le KL.
- On a besoin échantillon et comment échantillonner selon $h(\mathbf{u}_\theta)$ (qui n'est pas une distribution).

Remark: On va utiliser une méthode de bootstrap à poids qui va nous permettre d'échantillonner selon une densité proportionnelle à $h(\mathbf{u}_\theta)$ sans connaître la densité. Ensuite on fera un entraînement de type flot matching.

- Bootstrap à poids:
 - On échantillonne n points uniformément dans le domaine \mathbf{x}_i .
 - On calcule les poids $w_i = \frac{h(\mathbf{u}_\theta)(\mathbf{x}_i)}{\sum_{j=1}^n h(\mathbf{u}_\theta)(\mathbf{x}_j)}$
 - On rééchantillonne n points avec remplacement selon les poids w_i pour obtenir des points $\mathbf{x}_i \sim p_{\theta_p}$
- Comment échantillonner avec les poids
 - on crée des variables cumulatives $c_i = \sum_{j=1}^i w_j$
 - on tire $p \in \mathcal{U}[0, 1]$ et on cherche i tel que $c_{i-1} \leq p < c_i$

Applications

- Super resolution d'images




Figure 8: Super resolution d'images avec flow matching. Flow matching paper

- Génération de protéine
- Génération de turbulence etc